

- ★ Mục tiêu và chiến lược crawl
- ★ Logic và luồng hoạt động
- ★ Các thư viện và công nghệ được sử dụng
- ★ Giải thích từng bước chính trong notebook
- ★ Nguyên lý hoạt động tổng thể

Bắt đầu với file đầu tiên: detailJobsTopcv_scraper.ipynb.

 Tài liệu: Chiến lược và logic của detailJobsTopcv_scraper.ipynb

Tên file: detailJobsTopcv_scraper.ipynb

Mục tiêu: Crawl dữ liệu chi tiết của từng tin tuyển dụng từ trang web TopCV dựa trên danh sách các URL đã có.

1. Mục tiêu chính:

- Truy cập từng đường link chi tiết của công việc từ TopCV.
- Trích xuất thông tin: tên công việc, mô tả, yêu cầu, mức lương, công ty, địa điểm, kỹ năng, cấp bậc, số lượng, giới tính, độ tuổi,...
- Ghi dữ liệu vào DataFrame và lưu thành file CSV.

2. Công nghệ và thư viện sử dụng:

- requests: gửi HTTP GET requests.
- BeautifulSoup (bs4): phân tích cú pháp HTML.
- pandas: tạo và lưu DataFrame.

- time: chờ giữa các request tránh bị block IP.
- tqdm: hiển thị tiến trình xử lý.

3. Luồng hoạt động và logic chính:

Step 1: Đọc danh sách URL

- Mở file `topcv_links.csv` chứa danh sách đường dẫn đến các trang chi tiết công việc.
- Loại bỏ các dòng bị lỗi hoặc không có URL hợp lệ.

Step 2: Tạo hàm crawl chi tiết

- Hàm `get_job_detail(url)` sẽ:
 - Gửi request tới URL.
 - Phân tích cú pháp HTML để lấy thông tin từ các phần tử như:
 - Tiêu đề, công ty, địa điểm, mô tả công việc, yêu cầu,...
 - Dữ liệu được lưu thành dict.

Step 3: Lặp qua từng URL

- Sử dụng `tqdm` để hiển thị tiến trình.
- Gọi hàm `get_job_detail` cho mỗi URL.
- Thêm dữ liệu vào danh sách.

Step 4: Lưu dữ liệu

- Chuyển danh sách các dict thành pandas DataFrame.

- Lưu thành file CSV.

4. Nguyên lý hoạt động:

- Phương pháp crawl chi tiết được gọi là “detail-page scraping”.
- Danh sách URL được thu thập trước đó từ trang tổng hợp (multipage).
- Mỗi request được xử lý cẩn thận và thêm delay để tránh bị chặn.
- Dữ liệu được trích xuất có cấu trúc rõ ràng, dễ xử lý sau này (phân tích hoặc training ML).

 Tiếp theo: Tài liệu cho multipage_topcv_scraper.ipynb

Tên file: multipage_topcv_scraper.ipynb

Mục tiêu: Thu thập danh sách URL của các công việc từ nhiều trang kết quả tìm kiếm trên TopCV.

1. Mục tiêu chính:

- Duyệt qua nhiều trang kết quả tuyển dụng (pagination).
- Trích xuất URL của từng bài tuyển dụng.
- Lưu danh sách link vào CSV để sử dụng cho crawl chi tiết.

2. Công nghệ và thư viện:

- requests
- BeautifulSoup
- time

- tqdm
- pandas

3. Luồng hoạt động:

Step 1: Xác định URL gốc

- Trang tuyển dụng chính (ví dụ: <https://www.topcv.vn/viec-lam>)

Step 2: Xây dựng vòng lặp phân trang

- Duyệt từ page 1 đến N (ví dụ 100).
- Gửi request đến từng trang kết quả (ví dụ: ?page=1, ?page=2,...).
- Dùng BeautifulSoup để tìm tất cả thẻ chứa link đến bài tuyển dụng.

Step 3: Lưu dữ liệu

- Lưu danh sách link vào list.
- Tạo DataFrame và lưu ra CSV (topcv_links.csv).

4. Nguyên lý hoạt động:

- Sử dụng chiến lược “listing-page crawling”.
- Crawl tất cả các trang kết quả để lấy các link chi tiết.
- Tối ưu hóa tốc độ bằng cách dùng tqdm và time.sleep nhẹ để tránh bị chặn.

Tổng quan hệ thống:

- multipage_topcv_scraper → crawl link chi tiết → lưu topcv_links.csv
- detailJobsTopcv_scraper → crawl từng job từ link → lưu thông tin chi tiết ra file